
QUAL IA ESCOLHER?
GPT
Gemini
Claude
Copilot
Grok
Meta AI
Perplexity

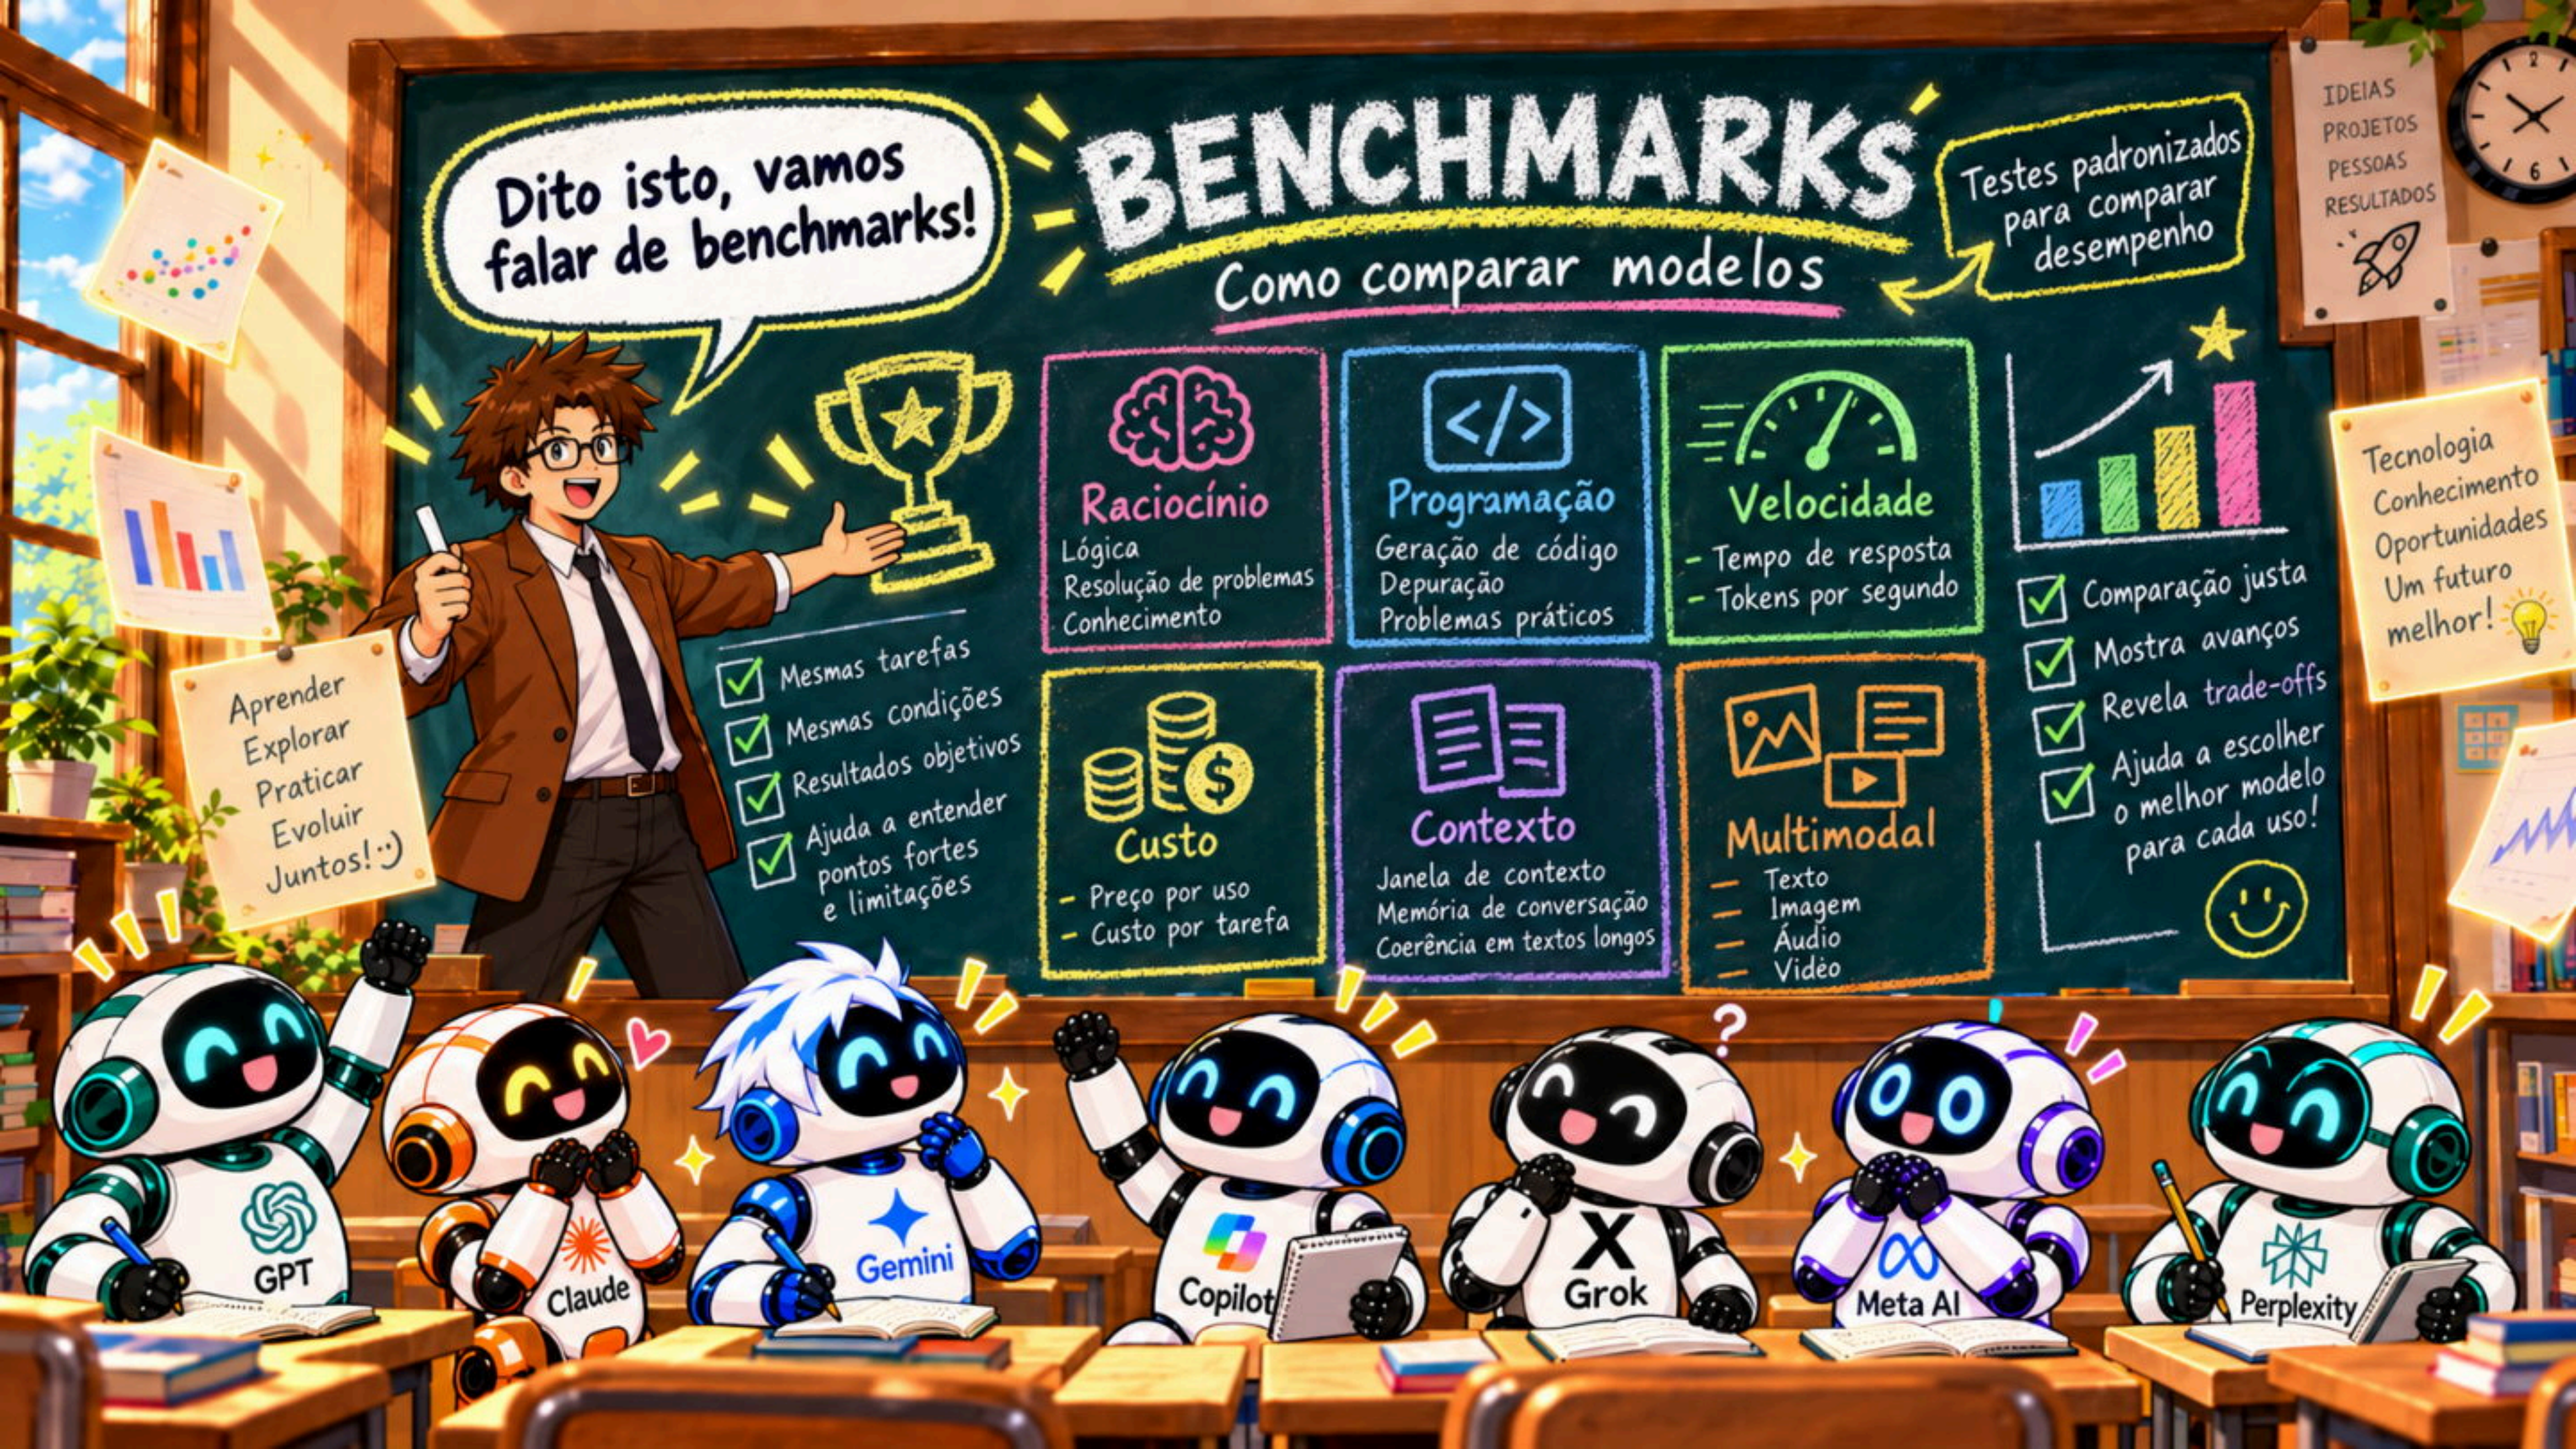

AGORA, TODO MUNDO A LIMPAR!
PAPÉIS
LIVROS
MESA
CHÃO
LOUSA
CADEIRAS
GPT
Claude
Gemini
Copilot
Grok
Meta AI
Perplexity
IA

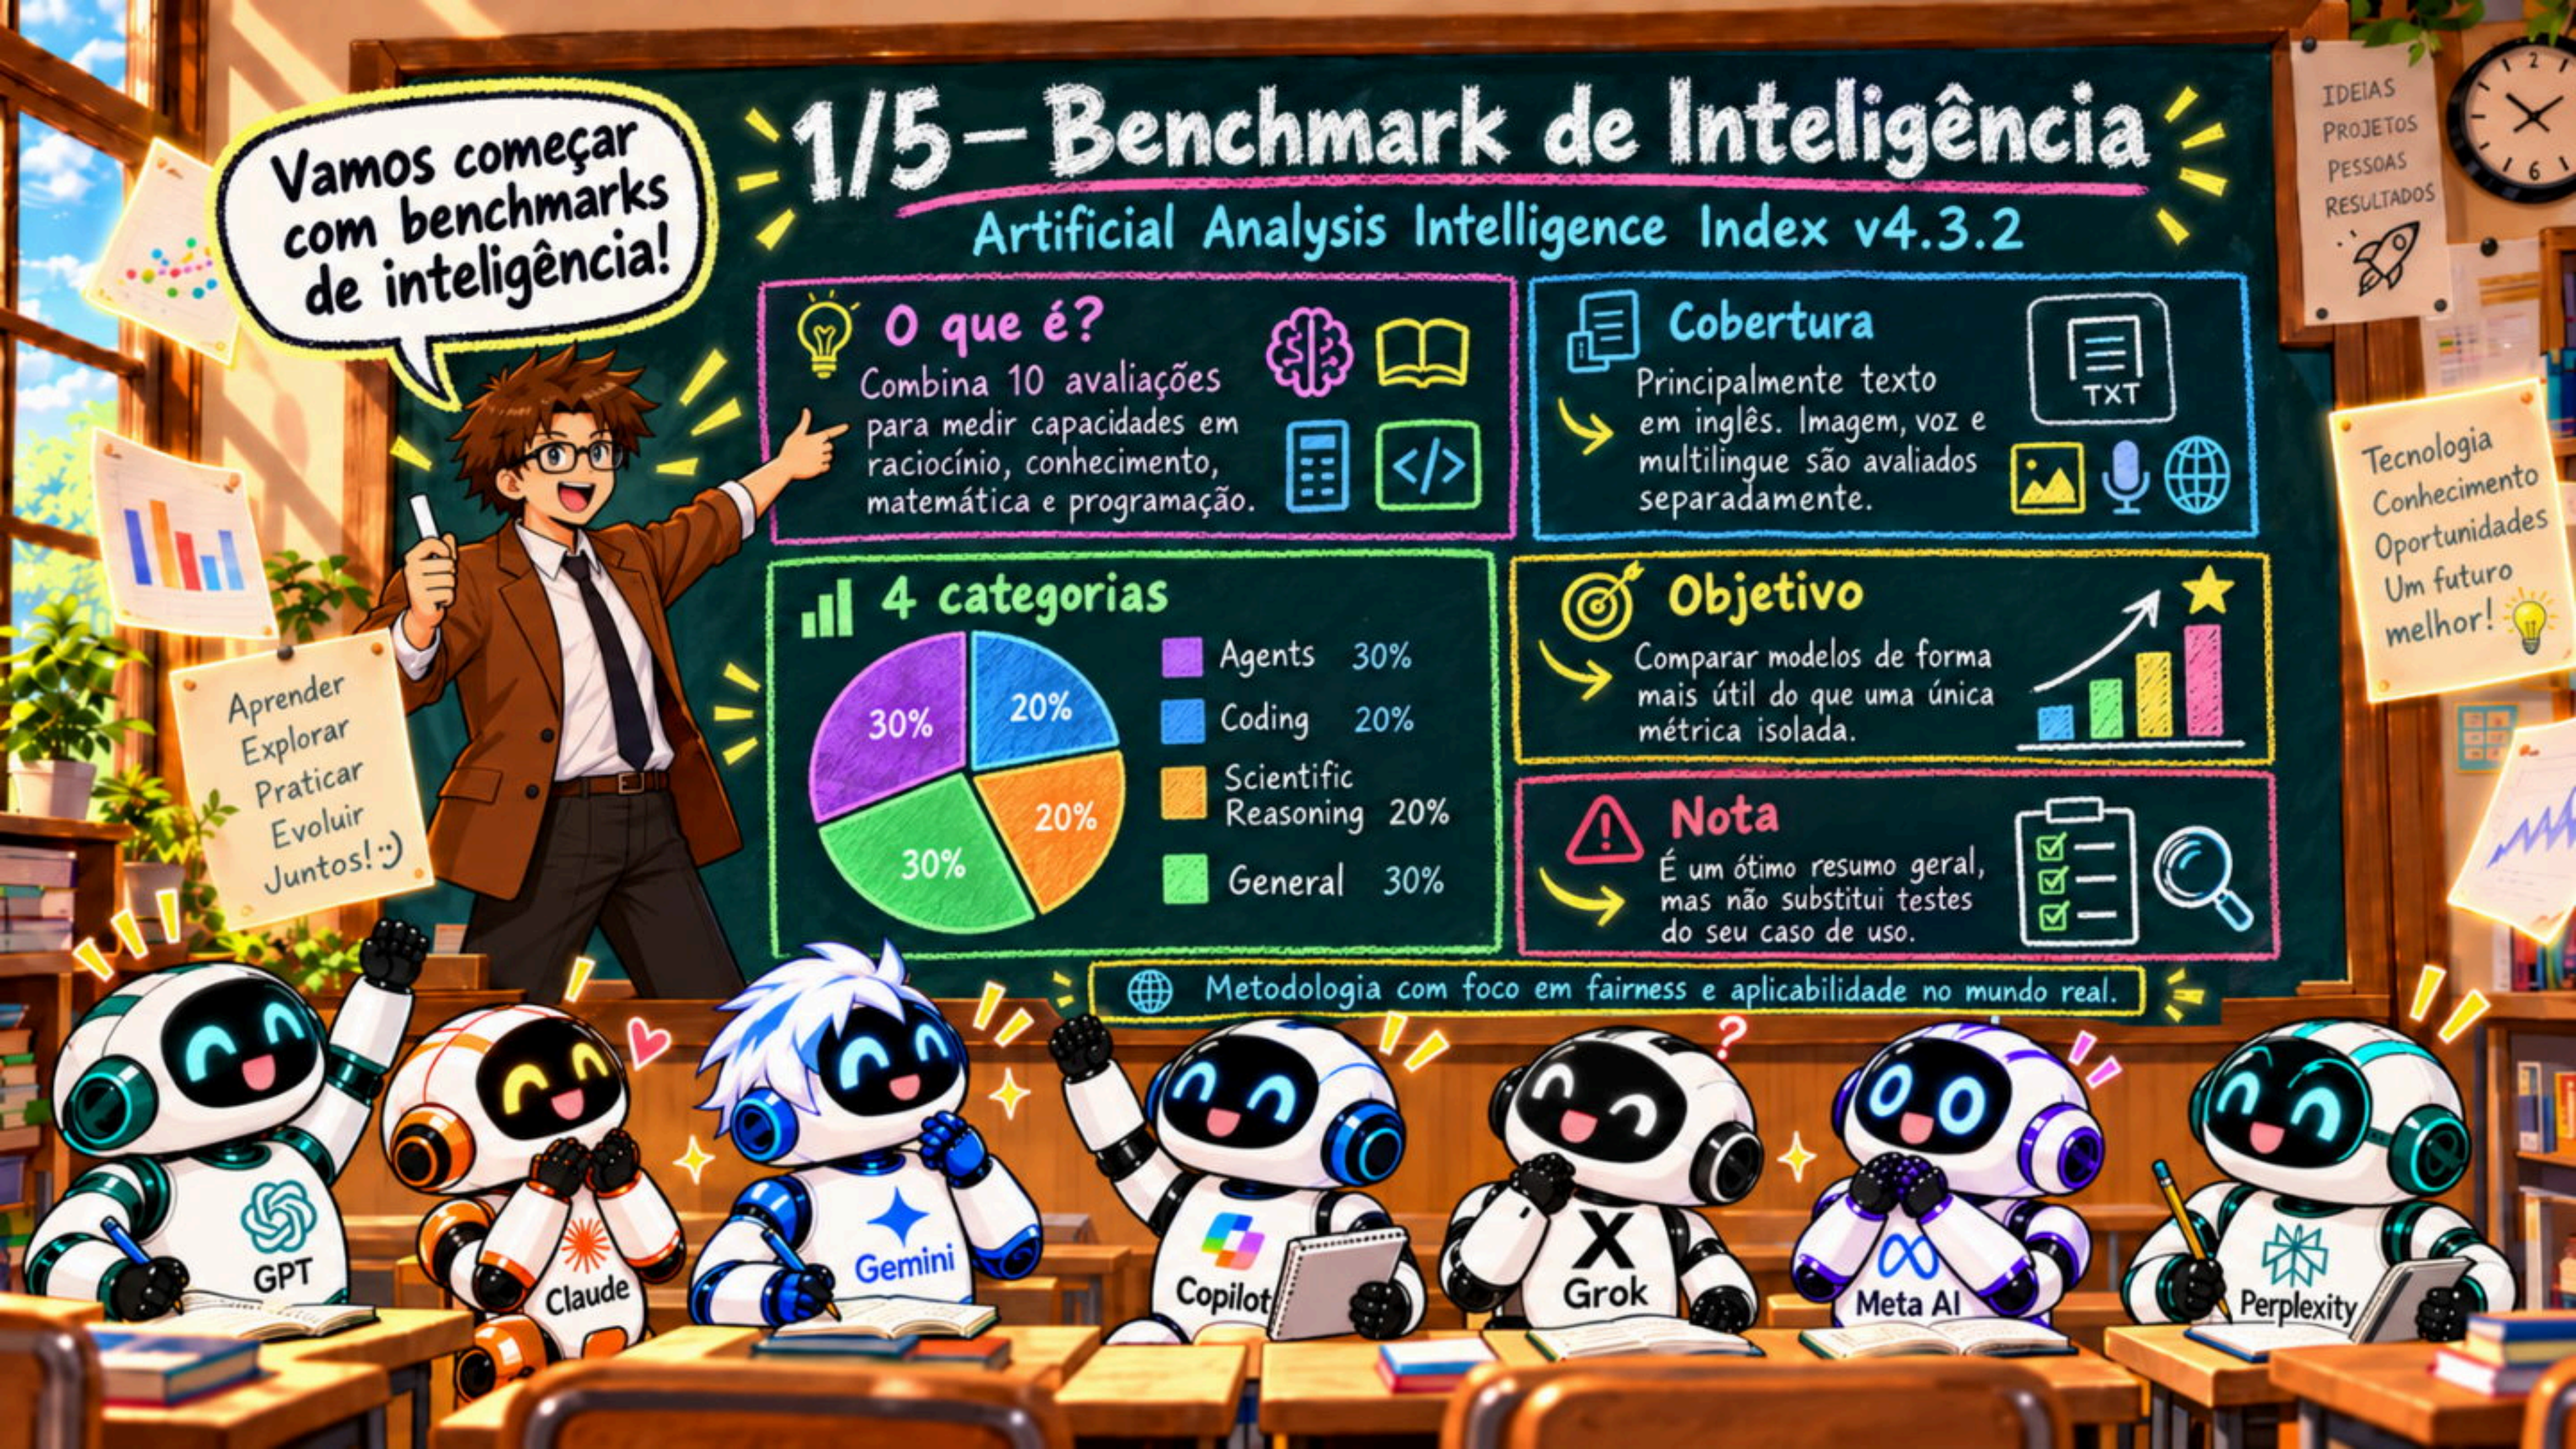

Como eu escolho um modelo para performar uma tarefa?
como escolher o modelo certo
OBJETIVO
TIPO DE TAREFA
CRITÉRIOS
• QUALIDADE
• VELOCIDADE
• CUSTO
• CONTEXTO
ESCOLHA DO MODELO
MESMA TAREFA, DIFERENTES PONTOS FORTES!
GPT
Claude
Gemini
Copilot
Grok
Meta AI
Perplexity

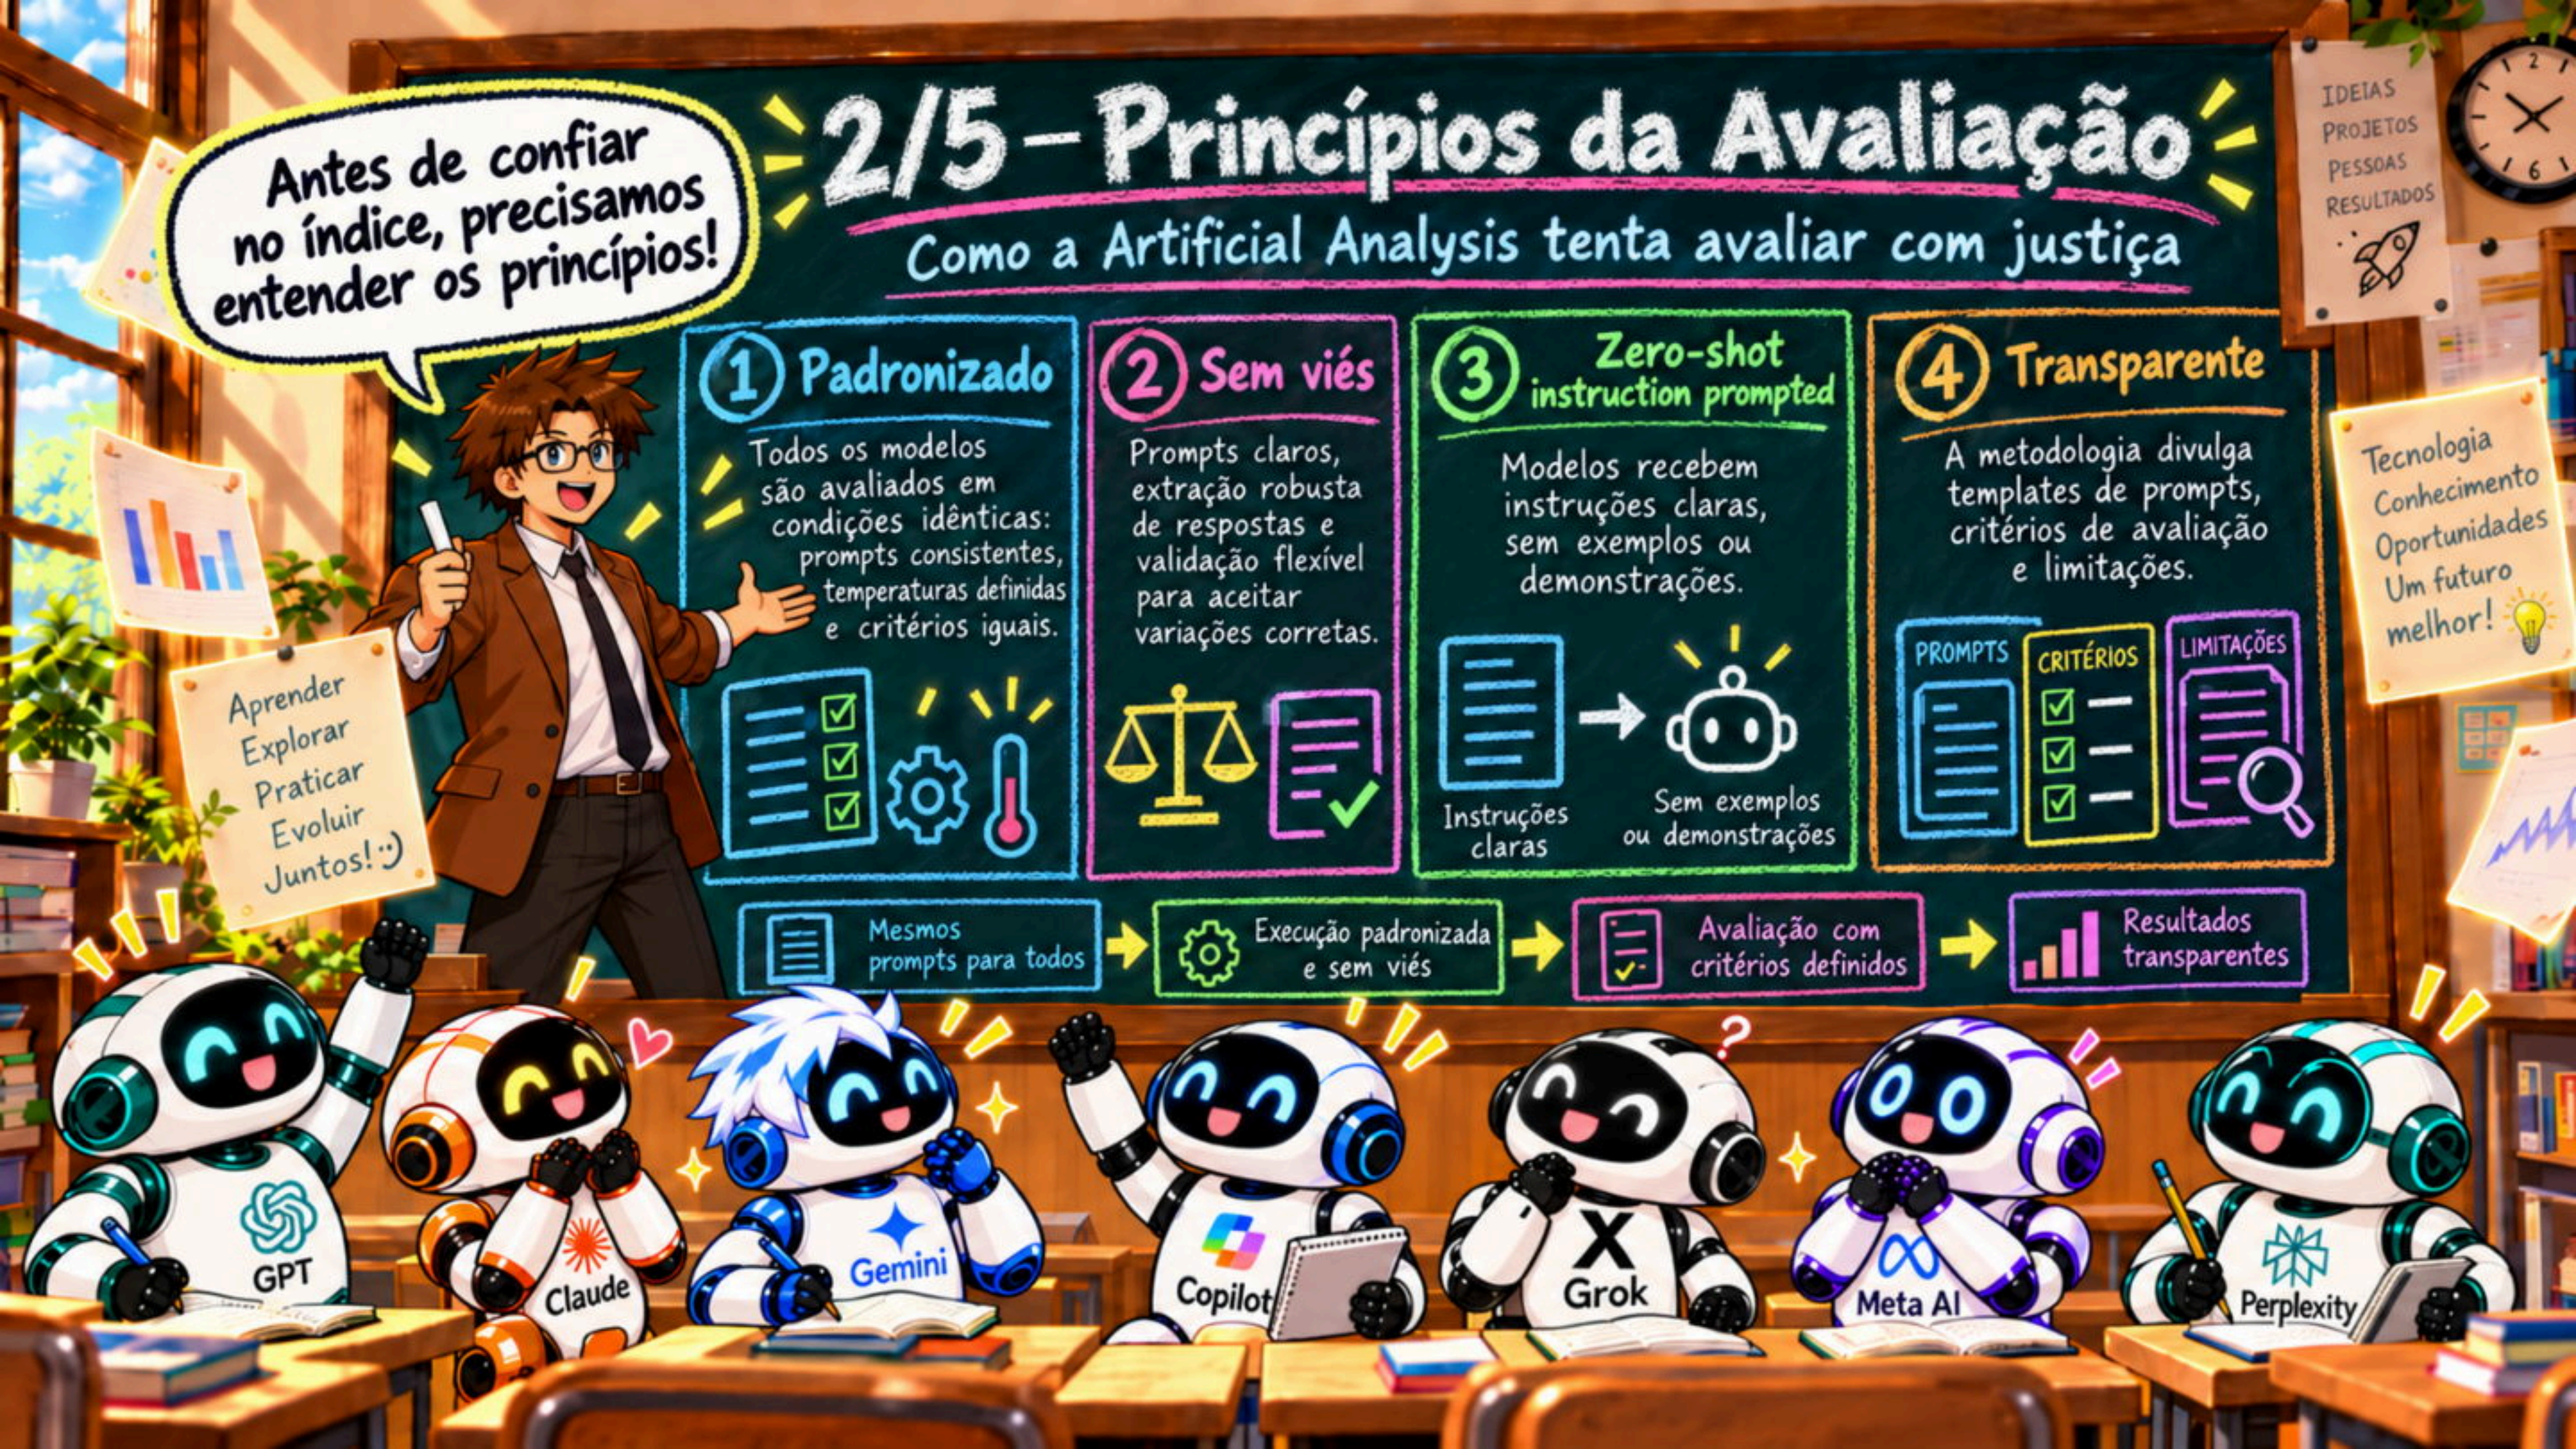

Leaderboard de Modelos
1 GPT-4o 82
2 Claude 3.5 79
3 Gemini 1.5 76
4 Copilot 74
5 Grok 2 72
6 Meta Llama 3
7 Perplexity
Artificial Analysis
o mundo encantado da pesquisa de modelos
INTELIGÊNCIA
CUSTO
VELOCIDADE
CONTEXTO
QUALIDADE
EXPLORAR
COMPARAR
APRENDER
ESCOLHER
Inteligência vs. Custo
Inteligência
Custo (US$ / 1M tokens)
GPT
Claude
Gemini
Copilot
Grok
Meta AI
Perplexity
Tempo por Tarefa
Análises Reais Independentes e Confiáveis
Comparação Detalhada
Desempenho
Preço
Velocidade
Janela de Contexto
Recursos Especiais
Melhores Casos de Uso
Precisão em Diferentes Tarefas
Raciocínio
Programação
Conhecimento
Matemática
Multimodal
GPT
Claude
Gemini
Copilot
Grok
Meta AI
Perplexity

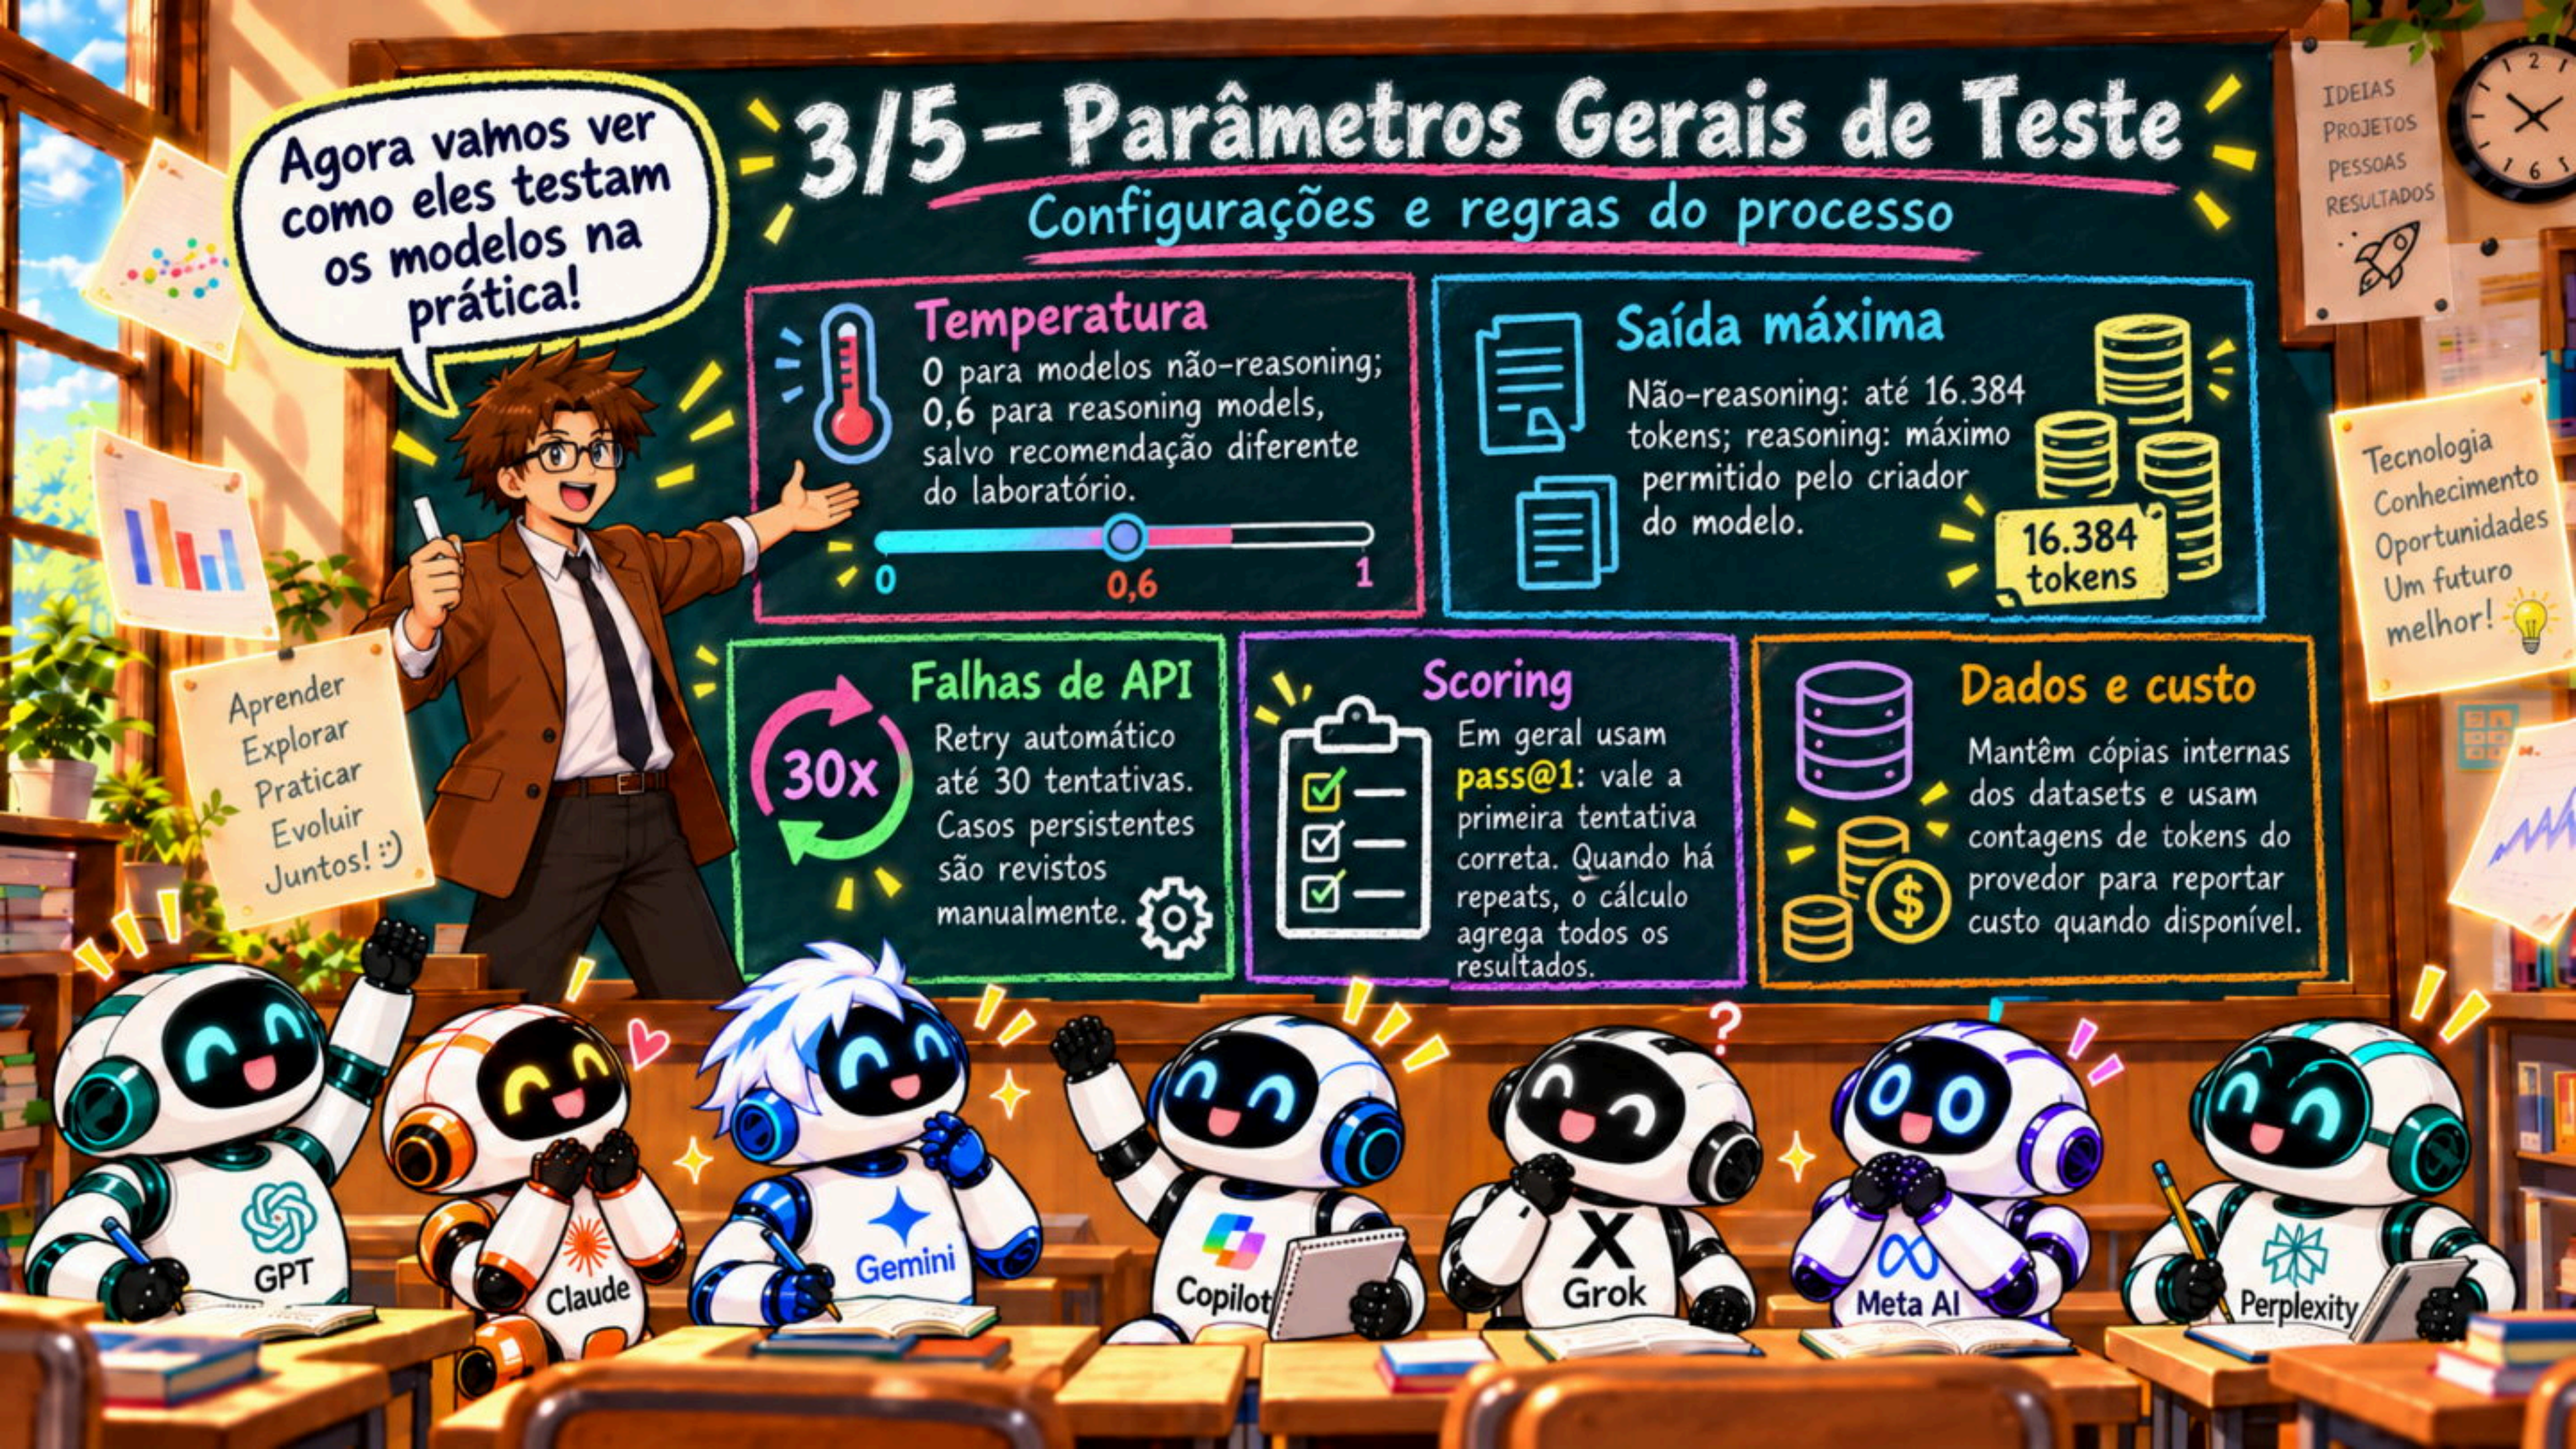

Podem entrar, salvem nos favoritos porque vocês vão usar!
ENTREM AQUI
Acesso rápido à página!
Site
Materiais
Tutoriais
Exemplos
Atividades
Tudo em um só lugar!
Escaneie o QR Code
Abra o link
Salve nos favoritos
Vocês vão usar nas próximas aulas!
IDEIAS
PROJETOS
PESSOAS
RESULTADOS
Tecnologia
Conhecimento
Oportunidades
Um futuro melhor!
Aprender
Explorar
Praticar
Evoluir
Juntos! :)
GPT
Claude
Gemini
Copilot
Grok
Meta AI
Perplexity


E agora vou lhes dar um gostinho do que é esta ciência dos benchmarks e quanto complexos podem ser!
O QUE SÃO BENCHMARKS?
É MAIS COMPLEXO DO QUE PARECE!
Conjuntos de dados
vários domínios e formatos
Métricas
Precisão
Raciocínio
Factualidade
Segurança
Criatividade
Eficiência
e muito mais!
Cenários de teste
Perguntas
Geração de código
Resumo
Agentes
Uso de ferramentas
...
Comparações
GPT
Claude
Gemini
Grok
Llama
Variáveis que influenciam
Modelo e versão
Dataset e splits
Prompt e formato
Configurações de inferência (temperatura, etc)
Hardware e custo
...
Trade-offs
Qualidade
Custo
Latência
Segurança
Robustez
Generalização
...
IDEIAS
PROJETOS
PESSOAS
RESULTADOS
Tecnologia
Conhecimento
Oportunidades
Um futuro melhor!
Aprender
Explorar
Praticar
Evoluir
Juntos! :)
GPT
Claude
Gemini
Copilot
Grok
Meta AI
Perplexity

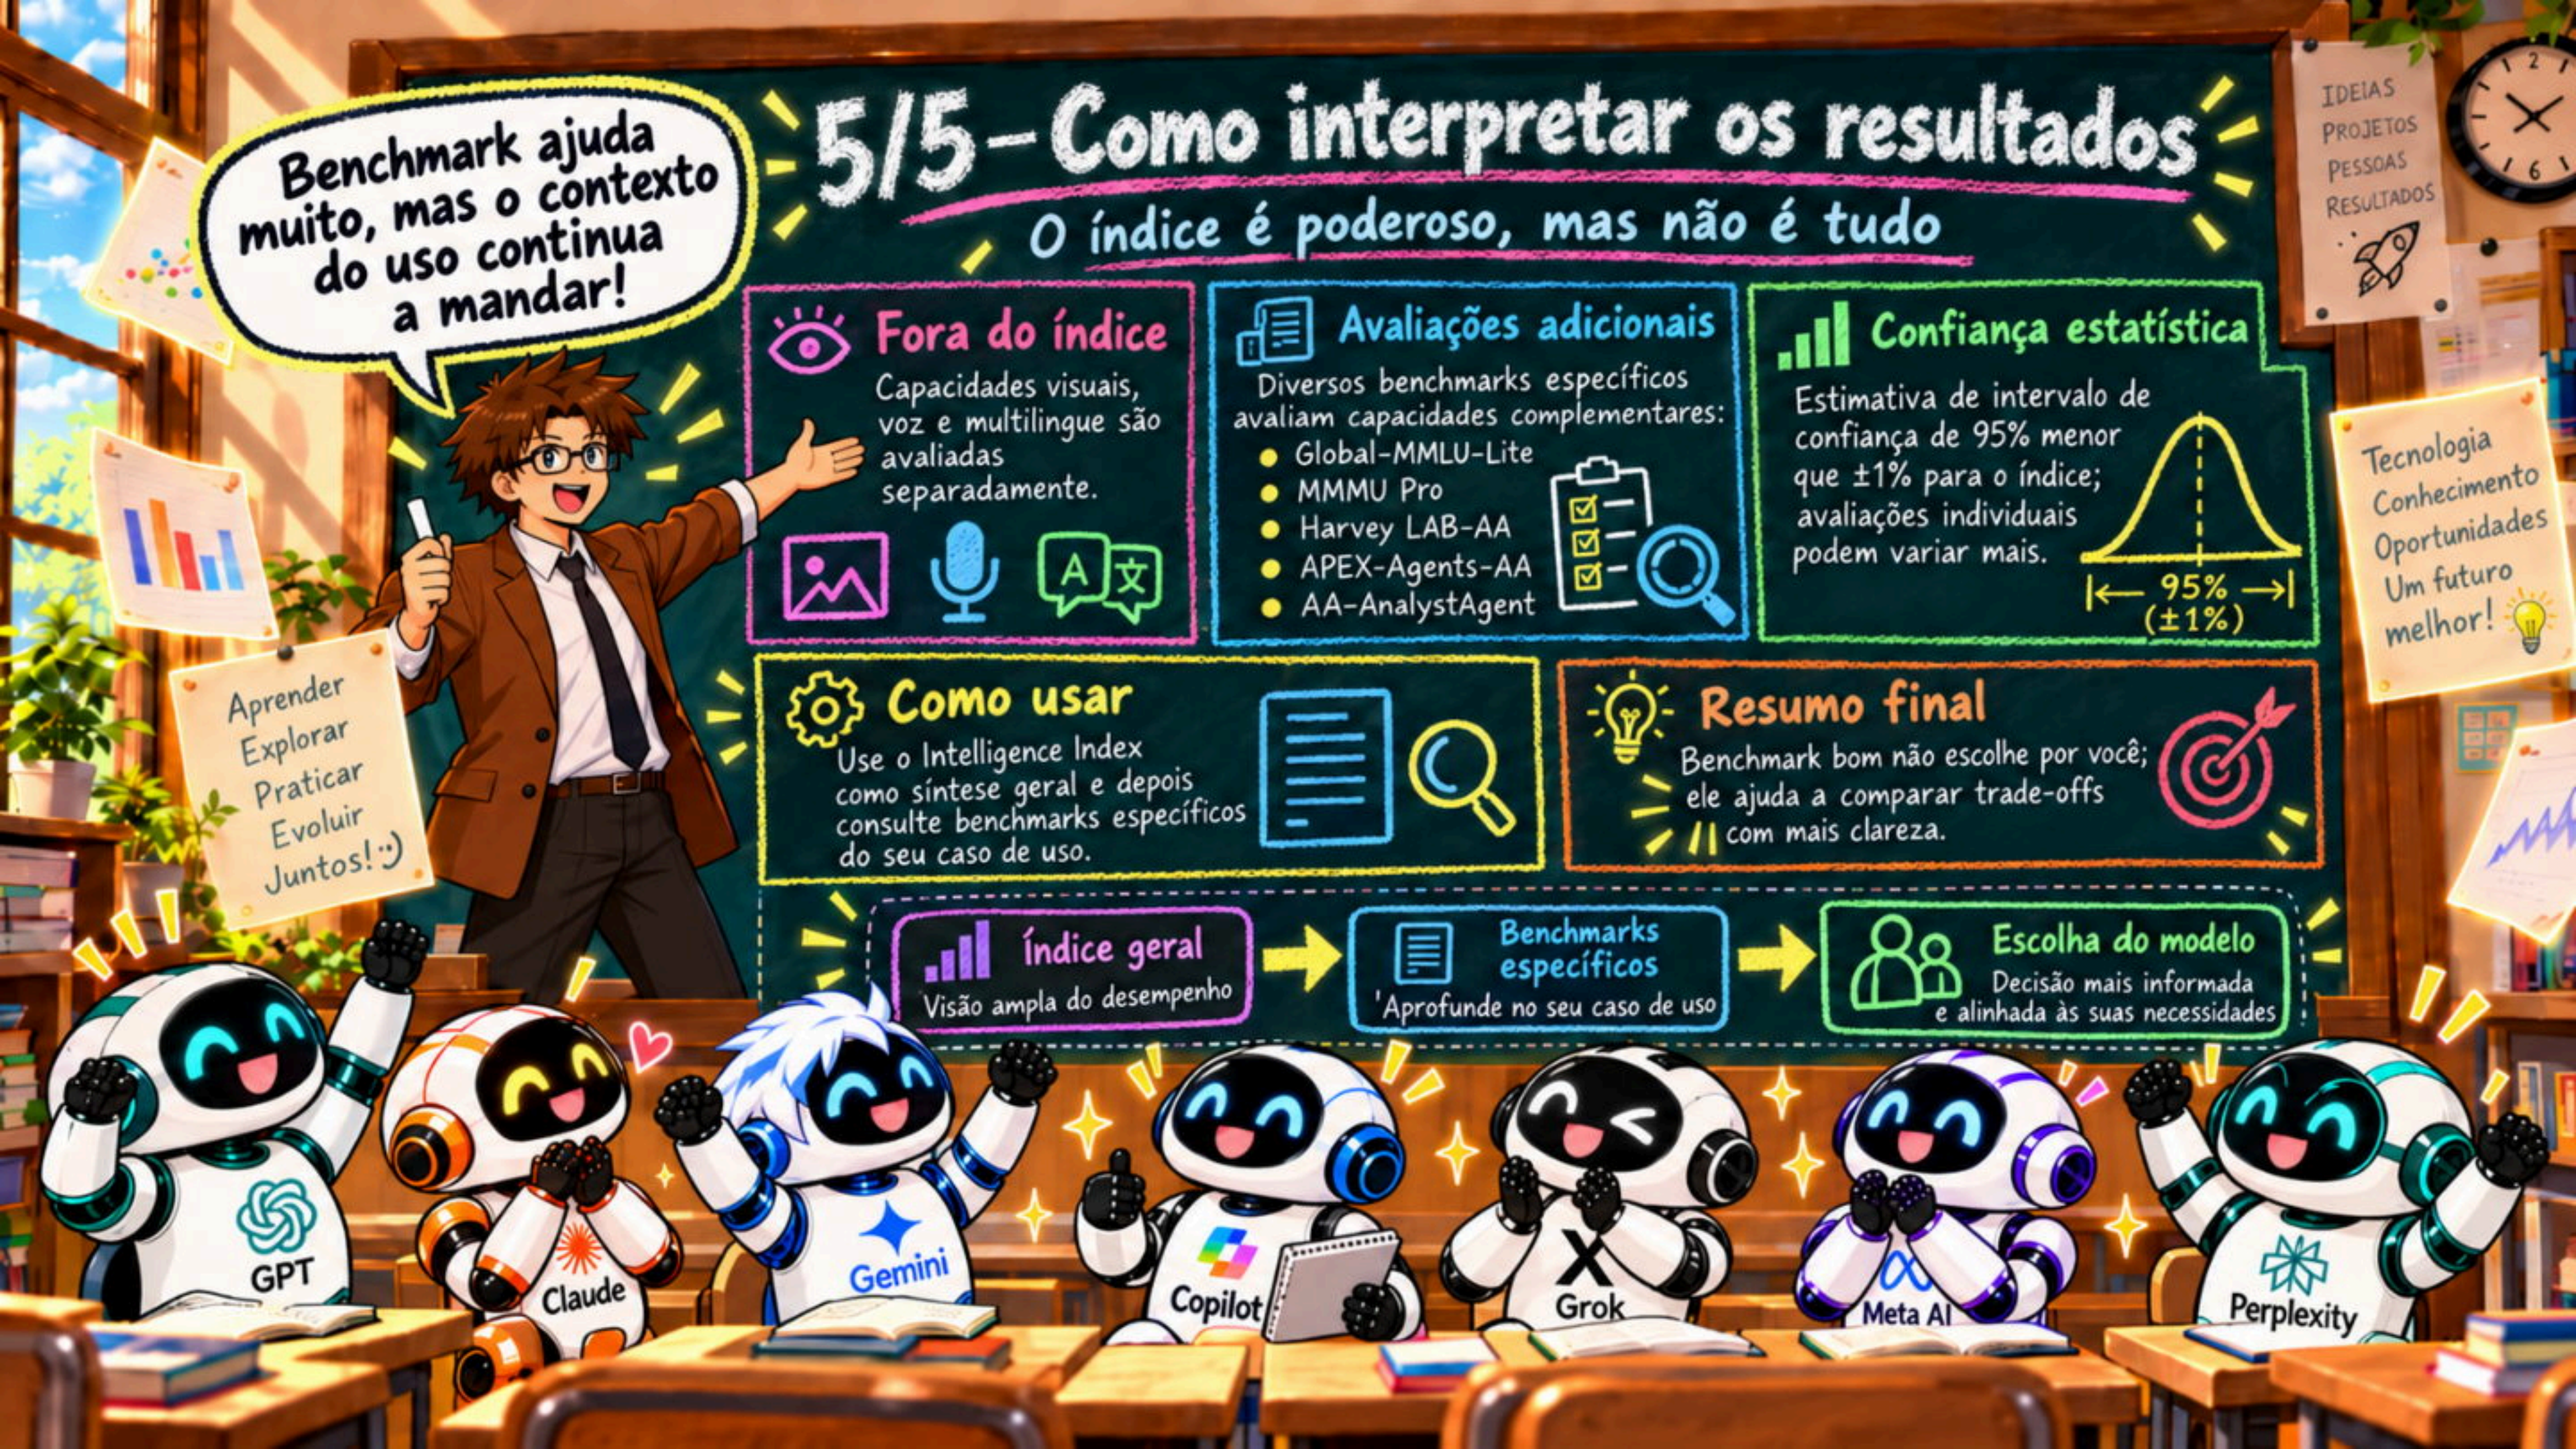

Dito isto, vamos falar de benchmarks!
BENCHMARKS
Como comparar modelos
Testes padronizados para comparar desempenho
Raciocínio
Lógica
Resolução de problemas
Conhecimento
Programação
Geração de código
Depuração
Problemas práticos
Velocidade
- Tempo de resposta
- Tokens por segundo
Custo
- Preço por uso
- Custo por tarefa
Contexto
Janela de contexto
Memória de conversação
Coerência em textos longos
Multimodal
- Texto
- Imagem
- Áudio
- Vídeo
Mesmas tarefas
Mesmas condições
Resultados objetivos
Ajuda a entender pontos fortes e limitações
Comparação justa
Mostra avanços
Revela trade-offs
Ajuda a escolher o melhor modelo para cada uso!
Aprender
Explorar
Praticar
Evoluir
Juntos! :)
IDEIAS
PROJETOS
PESSOAS
RESULTADOS
Tecnologia
Conhecimento
Oportunidades
Um futuro melhor!
GPT
Claude
Gemini
Copilot
Grok
Meta AI
Perplexity


Vamos começar com benchmarks de inteligência!
1/5 – Benchmark de Inteligência
Artificial Analysis Intelligence Index v4.3.2
O que é?
Combina 10 avaliações para medir capacidades em raciocínio, conhecimento, matemática e programação.
Cobertura
Principalmente texto em inglês. Imagem, voz e multilingue são avaliados separadamente.
TXT
4 categorias
30%
20%
20%
30%
Agents 30%
Coding 20%
Scientific Reasoning 20%
General 30%
Objetivo
Comparar modelos de forma mais útil do que uma única métrica isolada.
Nota
É um ótimo resumo geral, mas não substitui testes do seu caso de uso.
Metodologia com foco em fairness e aplicabilidade no mundo real.
Aprender
Explorar
Praticar
Evoluir
Juntos! :)
IDEIAS
PROJETOS
PESSOAS
RESULTADOS
Tecnologia
Conhecimento
Oportunidades
Um futuro melhor!
GPT
Claude
Gemini
Copilot
Grok
Meta AI
Perplexity


Antes de confiar no índice, precisamos entender os princípios!
2/5 – Princípios da Avaliação
Como a Artificial Analysis tenta avaliar com justiça
1 Padronizado
Todos os modelos são avaliados em condições idênticas: prompts consistentes, temperaturas definidas e critérios iguais.
2 Sem viés
Prompts claros, extração robusta de respostas e validação flexível para aceitar variações corretas.
3 Zero-shot instruction prompted
Modelos recebem instruções claras, sem exemplos ou demonstrações.
Instruções claras
Sem exemplos ou demonstrações
4 Transparente
A metodologia divulga templates de prompts, critérios de avaliação e limitações.
PROMPTS
CRITÉRIOS
LIMITAÇÕES
Mesmos prompts para todos
Execução padronizada e sem viés
Avaliação com critérios definidos
Resultados transparentes
IDEIAS
PROJETOS
PESSOAS
RESULTADOS
Tecnologia
Conhecimento
Oportunidades
Um futuro melhor!
Aprender
Explorar
Praticar
Evoluir
Juntos! :)
GPT
Claude
Gemini
Copilot
Grok
Meta AI
Perplexity


Agora vamos ver como eles testam os modelos na prática!
3/5 – Parâmetros Gerais de Teste
Configurações e regras do processo
Temperatura
0 para modelos não-reasoning; 0,6 para reasoning models, salvo recomendação diferente do laboratório.
0
0,6
1
Saída máxima
Não-reasoning: até 16.384 tokens; reasoning: máximo permitido pelo criador do modelo.
16.384 tokens
Falhas de API
30x
Retry automático até 30 tentativas. Casos persistentes são revistos manualmente.
Scoring
Em geral usam pass@1: vale a primeira tentativa correta. Quando há repeats, o cálculo agrega todos os resultados.
Dados e custo
Mantêm cópias internas dos datasets e usam contagens de tokens do provedor para reportar custo quando disponível.
Aprender
Explorar
Praticar
Evoluir
Juntos! :)
IDEIAS
PROJETOS
PESSOAS
RESULTADOS
Tecnologia
Conhecimento
Oportunidades
Um futuro melhor!
GPT
Claude
Gemini
Copilot
Grok
Meta AI
Perplexity


Aqui está a estrutura do Intelligence Index!
4/5 — O que entra no Intelligence Index
10 avaliações em 4 categorias
Agents 30%
AA-Briefcase v1.1 15%
GDPval-AA v2.1 10%
AutomationBench-AA 5%
Tarefas agentic do mundo real e de longa duração.
Coding 20%
Terminal-Bench 4.0 10%
SciCode 10%
Geração de código, depuração e raciocínio em programação.
Scientific Reasoning 20%
HLE 10%
CritPt 10%
Conhecimento científico e raciocínio em múltiplas disciplinas.
General 30%
AA-Omniscience 15%
GDP.pdf 10%
AA-LCR v1.1 5%
Conhecimento amplo, raciocínio e habilidades do mundo real.
A ponderação dá mais ênfase a tarefas agentic.
Aprender
Explorar
Praticar
Evoluir
Juntos! :)
IDEIAS
PROJETOS
PESSOAS
RESULTADOS
Tecnologia
Conhecimento
Oportunidades
Um futuro melhor!
GPT
Claude
Gemini
Copilot
Grok
Meta AI
Perplexity


Benchmark ajuda muito, mas o contexto do uso continua a mandar!
5/5 – Como interpretar os resultados
O índice é poderoso, mas não é tudo
Fora do índice
Capacidades visuais, voz e multilingue são avaliadas separadamente.
Avaliações adicionais
Diversos benchmarks específicos avaliam capacidades complementares:
Global-MMLU-Lite
MMMU Pro
Harvey LAB-AA
APEX-Agents-AA
AA-AnalystAgent
Confiança estatística
Estimativa de intervalo de confiança de 95% menor que ±1% para o índice; avaliações individuais podem variar mais.
95% (±1%)
Como usar
Use o Intelligence Index como síntese geral e depois consulte benchmarks específicos do seu caso de uso.
Resumo final
Benchmark bom não escolhe por você; ele ajuda a comparar trade-offs com mais clareza.
Índice geral
Visão ampla do desempenho
Benchmarks específicos
Aprofunde no seu caso de uso
Escolha do modelo
Decisão mais informada e alinhada às suas necessidades
Aprender
Explorar
Praticar
Evoluir
Juntos! :)
IDEIAS
PROJETOS
PESSOAS
RESULTADOS
Tecnologia
Conhecimento
Oportunidades
Um futuro melhor!
GPT
Claude
Gemini
Copilot
Grok
Meta AI
Perplexity


Agora vamos ver índices por profissão!
1/4 — Capability Indexes
O que são e para que servem
1 O que medem?
Desempenho de modelos em casos de uso profissionais específicos.
Legal
Healthcare & Medical
Finance & Accounting
Engineering
Economics
Strategy & Ops
2 Como são feitos?
Cada benchmark componente é executado de forma independente.
Depois os scores são combinados num índice do domínio.
Benchmarks independentes
Capacidades
Índice do domínio
3 Para que servem?
Ajudam a comparar modelos no trabalho que importa para uma área.
4 Importante
São uma síntese útil, mas têm limitações e não substituem testes do seu caso de uso.
Os benchmarks-base vêm da metodologia de Intelligence Benchmarking.
Aprender
Explorar
Praticar
Evoluir
Juntos!
IDEIAS
PROJETOS
PESSOAS
RESULTADOS
Tecnologia
Conhecimento
Oportunidades
Um futuro melhor!
GPT
Claude
Gemini
Copilot
Grok
Meta AI
Perplexity


2/4 — Capacidades e pesos
Como escolhem o que entra no índice
Os pesos vêm da frequência das tarefas no mundo real!
Cada índice mira uma profissão ou campo.
As ponderações seguem uma taxonomia estilo O*NET de atividades de trabalho.
O*NET
- Tarefas
- Atividades
- Frequência
- Relevância
- Pesos
Capacidades
Como são avaliadas
Conhecimento do domínio → AA-Omniscience
Agentic Knowledge Work → GDPval-AA v2.1 + AA-Briefcase v1.1
Reasoning → HLE
Engineering reasoning pode usar HLE + CritPt
Agentic Tool Use → AutomationBench-AA
Long-Context → LCR + GDP.pdf
Non-Hallucination → AA-Omniscience
Long-Context Reasoning → MLCR-AA (notar: usado em saúde)
Agentic Terminal Use → Terminal-Bench 4.0 (notar: usado em engineering)
Cada profissão usa uma mistura diferente destas peças.
Aprender
Explorar
Praticar
Evoluir
Juntos! :)
Ideias
Projetos
Pessoas
Resultados
Tecnologia
Conhecimento
Oportunidades
Um futuro melhor!
GPT
Claude
Gemini
Copilot
Grok
Meta AI
Perplexity


3/4 — Exemplos: negócio e direito
Como as ponderações mudam por área
Repare como a mistura muda de área para área!
Finance & Accounting Index
Business Knowledge AA-Omniscience 30%
Agentic Knowledge Work GDPval-AA v2.1 + AA-Briefcase v1.1 30%
Reasoning HLE 20%
Agentic Tool Use AutomationBench-AA 10%
Long-Context LCR, GDP.pdf 5%
Non-Hallucination AA-Omniscience 5%
Finanças, análise, spreadsheets, relatórios.
Strategy & Ops Index
Business Knowledge AA-Omniscience 30%
Agentic Knowledge Work GDPval-AA v2.1 + AA-Briefcase v1.1 35%
Agentic Tool Use AutomationBench-AA 30%
Long-Context LCR, GDP.pdf 5%
Operações, workflows, apps de negócio.
Legal Index
Legal Knowledge AA-Omniscience 35%
Agentic Knowledge Work GDPval-AA v2.1 + AA-Briefcase v1.1 25%
Reasoning HLE 15%
Long-Context LCR, GDP.pdf 10%
Non-Hallucination AA-Omniscience 10%
Agentic Tool Use AutomationBench-AA 5%
Leis, contratos, pesquisa, citações,
Mesmo benchmark-base, pesos diferentes conforme o trabalho real.
Aprender Explorar Praticar Evoluir Juntos!
IDEIAS PROJETOS PESSOAS RESULTADOS
Tecnologia Conhecimento Oportunidades Um futuro melhor!
GPT
Claude
Gemini
Copilot
Grok
Meta AI
Perplexity


4/4 – Saúde, engenharia e economia
Mais exemplos de capability indexes
Aqui vemos três perfis bem diferentes.
Aprender
Explorar
Praticar
Evoluir
Juntos! :)
Ideias
Projetos
Pessoas
Resultados
Tecnologia
Conhecimento
Oportunidades
Um futuro melhor!
Healthcare & Medical Index
Medical & Health Knowledge
AA-Omniscience
30%
Agentic Knowledge Work
GDPval-AA v2.1 + AA-Briefcase v1.1
25%
Long-Context Reasoning
MLCR-AA
15%
Non-Hallucination
AA-Omniscience
10%
Reasoning
HLE
10%
Agentic Tool Use
AutomationBench-AA
10%
Diagnóstico, guidelines, registos longos.
Engineering Index
Engineering Knowledge
AA-Omniscience
35%
Reasoning
HLE, CritPt
30%
Agentic Knowledge Work
GDPval-AA v2.1 + AA-Briefcase v1.1
20%
Agentic Terminal Use
Terminal-Bench 4.0
15%
Cálculos, trade-offs, terminal, debugging.
Economics Index
Economics Knowledge
AA-Omniscience
35%
Reasoning
HLE
35%
Agentic Knowledge Work
GDPval-AA v2.1 + AA-Briefcase v1.1
25%
Long-Context Reasoning
LCR
5%
Modelação, inferência, relatórios longos.
Escolha o índice que melhor aproxima o seu caso de uso.
Profissões diferentes pedem combinações diferentes de capacidades.
GPT
Claude
Gemini
Copilot
Grok
Meta AI
Perplexity


Eu poderia explicar todos os benchmarks para vocês, mas isso seria uma aula de 2 dias só para isso porque tem muita coisa.
4/4 – Saúde, engenharia e economia
Mais exemplos de capabiliity indexes
Engineering Index
35%
Economics Index
35%
35%
25%
Work
5%
Context Reasoning
Modelação, inferência, relatórios longos.


Então vamos focar no que importa: CUSTO vs COMPETÊNCIA!
CUSTO VS INTELIGÊNCIA VS LHT ESTABILITY


'Queremos usar os modelos para fazer coisas por nós! Vamos entrar aqui então!